

LABORATORIO DE DATOS


Primer Cuatrimestre 2024

Simulacro Parcial


1. Se quiere estimar el nivel de colesterol en sangre por regresión lineal utilizando los siguientes datos de los pacientes: índice de masa corporal, minutos de ejercicio físico diario, cantidad de grasas ingeridas por día. Si se agrega una nueva variable “último dígito del DNI del paciente”, y se compara con el modelo anterior mediante un esquema de entrenamiento y testeo, como espera que se modifique el error cuadrático medio (ECM):
 - a) Aumenta el ECM tanto en entrenamiento como en testeo.
 - b) Aumenta el ECM en entrenamiento y disminuye en testeo.
 - c) Disminuye el ECM en entrenamiento y aumenta en testeo.
 - d) Disminuye el ECM en entrenamiento y testeo.
2. ¿Cuál de los siguientes comandos de Python calcula correctamente el error cuadrático medio entre el vector respuesta y el vector de predicciones?
 - a) `np.sum((y - y_pred)**2) / len(y)`
 - b) `np.sum((y - y_pred))**2 / len(y)`
 - c) `(y.mean())**2 - (y_pred.mean())**2`
 - d) `np.mean(pd.concat([y, y_pred])**2)`
3. Decidir V o F.
 - a) Ambos métodos de clustering k -medias y DBSCAN son sensibles a la escala de los datos.
 - b) Como medida de centralidad de datos, la mediana es menos sensible a outliers que la media.
 - c) Clustering es un problema de aprendizaje supervisado.
 - d) KNN es un método de clasificación no paramétrico.
 - e) Regresión lineal es un método de aprendizaje supervisado y regresión Ridge es un método de aprendizaje no supervisado.
4. En la siguiente tabla se muestran las edades de los pacientes que recibió un médico un día. Se realiza un boxplot para resumir los datos (utilizando bigotes de longitud hasta 1.5 veces la distancia intercuartil). ¿Cuál de los cuatro box-plot es el correcto?

Index	1	2	3	4	5	6	7	8	9
Edad	12	15	27	35	37	40	45	50	84


Cuadro 1: Table of ages in one row




(a) Image 1



(b) Image 2



(c) Image 3



(d) Image 4

Figura 1: Four images arranged in two columns.

- 5.
6. Se quiere realizar un clustering con estos datos. ¿Cuál de las siguientes opciones considera que es la más apropiada?
 - a) k -medias con $k = 2$
 - b) k -medias con $k = 3$
 - c) DBSCAN con $\varepsilon = 0,2$ y $minPts = 20$
 - d) DBSCAN con $\varepsilon = 0,5$ y $minPts = 20$

7. Completar el código falta para cada uno de los siguientes gráficos.

a)

```
(  
    so.Plot(data = penguins, x = "bill_length_mm", y =  
    "bill_depth_mm", ???)  
    .add(so.Line(), so.PolyFit(1))  
)
```

```
(  
    so.Plot(data = penguins, ???)  
    .add(so.Bars(), so.Hist())  
)
```

b)

```
(  
    so.Plot(???)  
    .add(so.Bars(), so.Hist())  
)
```

```
(  
    so.Plot(data = gapminder, ???)  
    .add(so.Line())  
)
```

8) Para el siguiente conjunto de datos, aplicar en Python alguna técnica de clustering para obtener clusters como los de la figura de la derecha

9. Para el conjunto de datos en el archivo `datos.csv`, calcular:

a) El promedio de la variable “altura”.

b) El peso medio para