

LABORATORIO DE DATOS

Primer Cuatrimestre 2024

Simulacro Parcial

1. ¿Cuál de los siguientes comandos de Python calcula correctamente el error cuadrático medio entre el vector respuesta y el vector de predicciones?

- a) `np.sum((y - y_pred)**2) / len(y)`
- b) `np.sum((y - y_pred))**2 / len(y)`
- c) `(y.mean())**2 - (y_pred.mean())**2`
- d) `np.mean(pd.concat([y, y_pred])**2)`

2. Decidir V o F.

- a) Ambos métodos de clustering k -medias y DBSCAN son sensibles a la escala de los datos.
- b) Clustering es un problema de aprendizaje supervisado.

3. Utilizando la base de datos de pingüinos, completar:


- Peso promedio de los pingüinos de la especie Adelie.
- Peso promedio de los pingüinos de la especie Adelie que viven en la Isla Dream.
- Para cada isla, el desvío estándar del peso de los pingüinos que viven en esa isla.

4. Utilizando las edades de los pacientes que recibió un médico un día, se realiza un boxplot para resumir los datos (utilizando bigotes de longitud hasta 1.5 veces la distancia intercuartil).


Si los datos tienen las siguientes propiedades:

- Media: 43
- Mediana: 37
- Máximo: 100
- Mínimo: 15


¿Cuál de los cuatro box-plot es el correcto?




(a)



(b)




(c)




(d)

5. Se quiere realizar un clustering con estos datos. ¿Cuál de las siguientes opciones considera que es la más apropiada?



- a) k -medias con $k = 2$
- b) k -medias con $k = 3$
- c) DBSCAN con $\varepsilon = 0,2$ y $minPts = 20$
- d) DBSCAN con $\varepsilon = 0,8$ y $minPts = 20$

6. Ingresar un código para generar el siguiente gráfico a partir de datos de Gapminder.



Pueden utilizar el siguiente código para cargar los datos de Gapminder.

```
from gapminder import gapminder
```