

Laboratorio de Datos

Entrenamiento y testeo

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Aprendizaje Supervisado y No Supervisado

Aprendizaje Supervisado:

- El objetivo es predecir una variable respuesta a partir de variables explicativas.
- Conocemos la respuesta correcta para un conjunto de datos y usamos esos datos para construir el modelo.
- Ejemplos: regresión, clasificación.


Aprendizaje No Supervisado:

- El objetivo es encontrar patrones o estructuras ocultas en los datos.
- No conocemos o no hay a priori una respuesta correcta.
- Ejemplos: agrupación (clustering), reducción de dimensionalidad.


Introducción a la Agrupación

En las últimas clases estudiamos modelos de regresión (aprendizaje supervisado).
Estudiamos ahora métodos de agrupamiento (clustering).


- La agrupación es una técnica de aprendizaje no supervisado.
- El objetivo es agrupar datos similares en conjuntos llamados clústeres.
- Aplicaciones: segmentación de mercado, análisis de redes sociales, imágenes médica, etc.




Aplicaciones: segmentación de mercado



Aplicaciones: imágenes médicas



(a)




(b)

Clustering por K -medias (K -means)

Existen diversos algoritmos de clustering. El algoritmo k -medias comenzó a utilizarse en los alrededores de 1960.

- K -means es un algoritmo de agrupación que particiona los datos en k clústeres.
- Se definen k centros para los clusters.
- Se supone que cada cluster es un conjunto de datos que están razonablemente bien aproximados por el centro del cluster (el promedio de los valores del cluster).



Algoritmo k -means (ingenuo)

Comenzamos con un conjunto arbitrario de centros (por ejemplo k puntos al azar).

Ahora repetimos los siguientes dos pasos hasta "alcanzar convergencia":



- 1 Actualizamos las etiquetas: para cada punto, buscamos cuál es el centro más cercano a ese punto y lo asignamos a ese cluster.
- 2 Actualizamos los centros: para cada cluster, recalculamos el centro del cluster como el promedio de todo los datos del cluster (si los puntos tienen varias coordenadas, calculamos el promedio de cada coordenada).

¿Qué significa en este caso alcanzar convergencia?

Que las etiquetas no cambien de un paso al siguiente.



Ejemplos

¿En cuál de estos casos, los clusters quedarán bien definidos a partir de sus centros?



Ejemplos



¿En cuál de estos casos, los clusters quedarán bien definidos a partir de sus centros?



Aplicaciones de k -means

¿En cuáles de estas aplicaciones el método de k -means puede resultar apropiado?

- 1 Clasificar especies animales según características (peso, largo, longitud de la cola, ...).
- 2 Identificar distintas componentes de una imagen.





Procedimiento de K-means

- 1 Elegir k centroides iniciales aleatoriamente.
- 2 Asignar cada punto de datos al clúster más cercano (basado en la distancia euclidiana).
- 3 Calcular nuevos centroides como la media de los puntos asignados a cada clúster.
- 4 Repetir los pasos 2 y 3 hasta que los centroides no cambien significativamente.

¿Número óptimo de clusters?

- A medida que aumentamos la cantidad de clusters, el error WSS disminuye.
- Por lo tanto no hay un número óptimo de clusters.
- Podemos mirar la curva y ver cuándo aumentar la cantidad de clusters no reduce significativamente el error WSS.
- Este proceso suele llamarse “método del codo”.



Ventajas y Desventajas de K-means

Ventajas:

- Simple y fácil de implementar.
- Escalable para grandes conjuntos de datos.

Desventajas:

- Requiere especificar el número de clústeres (k) de antemano.
- Sensible a la elección de los centroides iniciales.
- Puede converger a mínimos locales.

K-medias como problema de optimización

Podemos plantear el problema de clustering por k -medias como un problema de optimización.

- Buscamos minimizar la "suma de los errores".
- Consideramos que los errores son las distancias de cada punto al centro de su cluster.
- Es decir, queremos minimizar la suma de los cuadrados dentro de cada cluster (WCSS o within cluster sum of squares).
- Formalmente queremos elegir centros S_i y etiquetas μ_i que minimicen:

$$\arg \min_{\mathbf{S}} \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

Aplicación de K-means en Python

- Ejemplo de implementación en Python usando scikit-learn:

```
from sklearn.cluster import KMeans
import numpy as np

# Datos de ejemplo
5 X = np.array([[1, 2], [1, 4], [1, 0],
               [10, 2], [10, 4], [10, 0]])

# Inicializar K-means
kmeans = KMeans(n_clusters=2, random_state=0).fit(X)

10 # Resultados
print(kmeans.labels_)
print(kmeans.cluster_centers_)
```