

Laboratorio de Datos

Entrenamiento y testeo

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Aprendizaje Supervisado y No Supervisado

Aprendizaje Supervisado:

- El objetivo es predecir una variable respuesta a partir de variables explicativas.
- Conocemos la respuesta correcta para un conjunto de datos y usamos esos datos para construir el modelo.
- Ejemplos: regresión, clasificación.


Aprendizaje No Supervisado:

- El objetivo es encontrar patrones o estructuras ocultas en los datos.
- No conocemos o no hay a priori una respuesta correcta.
- Ejemplos: agrupación (clustering), reducción de dimensionalidad.


Introducción a la Agrupación

En las últimas clases estudiamos modelos de regresión (aprendizaje supervisado).
Estudiamos ahora métodos de agrupamiento (clustering).


- La agrupación es una técnica de aprendizaje no supervisado.
- El objetivo es agrupar datos similares en conjuntos llamados clústeres.
- Aplicaciones: segmentación de mercado, análisis de redes sociales, imágenes médica, etc.




Aplicaciones: segmentación de mercado



Aplicaciones: imágenes médicas



(a)



(b)

Clustering por K -medias (K -means)

Existen diversos algoritmos de clustering.

- K -means es un algoritmo de agrupación que particiona los datos en k clústeres.
- Se definen k centros para los clusters.
- Para determinar el cluster al que corresponde cada elemento, se busca cuál es el centro más cercano.

Procedimiento de K-means

- 1 Elegir k centroides iniciales aleatoriamente.
- 2 Asignar cada punto de datos al clúster más cercano (basado en la distancia euclidiana).
- 3 Calcular nuevos centroides como la media de los puntos asignados a cada clúster.
- 4 Repetir los pasos 2 y 3 hasta que los centroides no cambien significativamente.

Ventajas y Desventajas de K-means

Ventajas:

- Simple y fácil de implementar.
- Escalable para grandes conjuntos de datos.

Desventajas:

- Requiere especificar el número de clústeres (k) de antemano.
- Sensible a la elección de los centroides iniciales.
- Puede converger a mínimos locales.

Aplicación de K-means en Python

- Ejemplo de implementación en Python usando scikit-learn:

```
from sklearn.cluster import KMeans
import numpy as np

# Datos de ejemplo
5 X = np.array([[1, 2], [1, 4], [1, 0],
                [10, 2], [10, 4], [10, 0]])

# Inicializar K-means
kmeans = KMeans(n_clusters=2, random_state=0).fit(X)

10 # Resultados
print(kmeans.labels_)
print(kmeans.cluster_centers_)
```