

Laboratorio de Datos

Clustering: k -medias

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Introducción a las Técnicas de Clasificación

- **Definición:** La clasificación es una técnica de aprendizaje supervisado donde el objetivo es predecir la categoría a la que pertenece una nueva observación, basada en un conjunto de datos de entrenamiento con categorías conocidas.
- **Aplicaciones Comunes:**
 - Diagnóstico médico (clasificación de enfermedades)
 - Reconocimiento de imágenes (clasificación de objetos)
 - Filtrado de correos electrónicos (spam vs no spam)

Técnicas Comunes de Clasificación

- **Regresión Logística:**

- Método estadístico para modelar la probabilidad de una variable binaria
- Utiliza una función logística para limitar los valores predichos entre 0 y 1

- **K-Vecinos Más Cercanos (K-NN):**

- Clasifica basándose en la mayoría de los vecinos más cercanos a un punto de datos
- Sencillo pero puede ser computacionalmente costoso

Otras Técnicas de Clasificación

- **Árboles de Decisión:**

- Modelo basado en reglas de decisión en forma de árbol
- Fácil de interpretar y visualizar


- **Máquinas de Vectores de Soporte (SVM):**

- Encuentra el hiperplano que maximiza el margen entre las diferentes clases
- Eficaz en espacios de alta dimensión

- **Redes Neuronales:**

- Modelos inspirados en el funcionamiento del cerebro humano
- Capaces de aprender representaciones complejas


Árboles de decisión: ejemplo



Support vector machine: ejemplo


Caso lineal

Separamos los puntos por rectas o planos.



Caso no lineal

Antes de separar por un plano, aplicamos una transformación de los datos.




Regresión Logística en 1 minuto

¿Cómo podemos predecir una variable respuesta binaria (0/1)?

Considerar a y como una variable numérica y ajustar una función lineal $y = \beta_0 + \beta_1 x$ no va a ser apropiado.

Queremos una función que para valores grandes positivos de x la función se acerque a 1 y para valores grandes negativos la función se acerque a 0.



Regresión Logística en 1 minuto

Le aplicamos una transformación a la función lineal.


En regresión logística tomamos

$$y = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}.$$

Si $\beta_1 > 0$, cuanto mas grande es x , más cercano a 1 es y .

Si tenemos varias variables explicativas, usamos


$$y = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}.$$



Regresión Logística en 1 minuto

Finalmente usamos la curva para clasificar.

$$y = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}.$$



Métodos paramétricos vs. no paramétricos




- Los modelos de regresión lineal o regresión logística son modelos paramétricos.
- Asumen una forma específica para la relación entre las variables independientes y la variable dependiente.
- Es decir, se define una ecuación paramétrica con un número fijo de parámetros (coeficientes) que determinan esta relación, por ejemplo
$$y = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}}.$$
- Los métodos paramétricos hacen suposiciones sobre la distribución de los datos y la estructura del modelo, lo que puede proporcionar predicciones más eficientes y precisas si estas suposiciones son correctas.

¿Cómo sería un método no-paramétrico?

Modelo no paramétrico para clasificación

Tenemos un conjunto de pingüinos para los que sabemos su especie, y queremos saber la especie de un nuevo pingüino.

¿A qué especie pertenece el pingüino rojo?



¿Qué es el Algoritmo K-Vecinos Más Cercanos (K-NN)?

- **Definición:**

- K-NN es un algoritmo de aprendizaje supervisado utilizado para clasificación y regresión.
- Se basa en la idea de que objetos similares están cerca unos de otros.

- **Funcionamiento:**

- Para clasificar un nuevo punto, el algoritmo busca los K puntos más cercanos en el conjunto de entrenamiento.
- La categoría más común entre estos K vecinos se asigna al nuevo punto.

Características y Aplicaciones del Algoritmo K-NN

- **Ventajas:**

- Fácil de entender e implementar.
- No requiere un modelo paramétrico, lo que lo hace flexible.

- **Desventajas:**

- Computacionalmente costoso para grandes conjuntos de datos debido a la necesidad de calcular distancias.
- El rendimiento puede verse afectado por la elección del valor de K y la escala de las características.
- Si tenemos muchas variables explicativas, sufriremos la maldición de la dimensionalidad.

Selección del K -óptimo

Como es un modelo de aprendizaje supervisado, podemos elegir el K óptimo con alguna estrategia de validación.

Esquema posible de validación:

- 1 Separamos el conjunto de todos los datos en 80 % entrenamiento y 20 % testeo
- 2 Elegimos el valor de K por validación cruzada en la muestra de entrenamiento.
- 3 Probamos la performance de nuestro modelo en la muestra testeo.

Preguntas:

- ¿Cuál es el valor a optimizar en la validación? Elegimos el valor de K que nos de el mayor porcentaje de aciertos.
- ¿Qué significa entrenar nuestro modelo? Como es un modelo no-paramétrico, no hay que aprender ningún parámetro. Entrenar es

Validación "leave-one-out"

Podemos hacer validación cruzada en pliegos:

- Dividimos nuestra muestra en 5 pliegos (o cualquier otra cantidad).
- Seleccionamos 4 pliegos para entrenamiento y 1 pliego para validación.
- Para cada uno de los datos de validación, buscamos los K vecinos más cercanos en los pliegos de entrenamiento.
- Elegimos el valor más votado entre los vecinos.

Validación leave-one-out.

- Es el caso extremo de validación en pliegos, donde cada observación es un pliego.
- Para cada observación, buscamos los K vecinos más cercanos entre todos los demás puntos.
- Elegimos el valor más votado entre los vecinos.

En modelos de regresión, validación leave-one-out puede ser costoso porque