

Laboratorio de Datos

Clustering: k -medias

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Introducción a las Técnicas de Clasificación

- **Definición:** La clasificación es una técnica de aprendizaje supervisado donde el objetivo es predecir la categoría a la que pertenece una nueva observación, basada en un conjunto de datos de entrenamiento con categorías conocidas.
- **Aplicaciones Comunes:**
 - Diagnóstico médico (clasificación de enfermedades)
 - Reconocimiento de imágenes (clasificación de objetos)
 - Filtrado de correos electrónicos (spam vs no spam)

Técnicas Comunes de Clasificación

- **Regresión Logística:**

- Método estadístico para modelar la probabilidad de una variable binaria
- Utiliza una función logística para limitar los valores predichos entre 0 y 1

- **K-Vecinos Más Cercanos (K-NN):**

- Clasifica basándose en la mayoría de los vecinos más cercanos a un punto de datos
- Sencillo pero puede ser computacionalmente costoso

- **Árboles de Decisión:**

- Modelo basado en reglas de decisión en forma de árbol
- Fácil de interpretar y visualizar

- **Máquinas de Vectores de Soporte (SVM):**

- Encuentra el hiperplano que maximiza el margen entre las diferentes clases
- Eficaz en espacios de alta dimensión

- **Redes Neuronales:**

- Modelos inspirados en el funcionamiento del cerebro humano
- Capaces de aprender representaciones complejas

Introducción a la Regresión Logística

- **Definición:**

- Técnica de aprendizaje supervisado utilizada para predecir la probabilidad de una variable binaria (0 o 1).

- **Aplicaciones:**

- Diagnóstico médico (ej. presencia o ausencia de enfermedad)
- Marketing (ej. probabilidad de compra de un producto)
- Finanzas (ej. riesgo de crédito)

- **Función Logística:**

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Características de la Regresión Logística

- **Interpretación de Coeficientes:**

- Los coeficientes (β_i) representan el cambio en el logaritmo de las probabilidades (log-odds) por unidad de cambio en el predictor.

- **Bondad del Ajuste:**

- Se utiliza el valor de *p-value* y pruebas como la devianza para evaluar el modelo.

- **Ventajas:**

- Fácil de implementar e interpretar
- Escalabilidad para grandes conjuntos de datos

- **Limitaciones:**

- Asume una relación lineal entre los predictores y el log-odds
- No funciona bien con datos altamente correlacionados (multicolinealidad)