

Laboratorio de Datos

Clustering: k -medias

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Introducción a las Técnicas de Clasificación

- **Definición:** La clasificación es una técnica de aprendizaje supervisado donde el objetivo es predecir la categoría a la que pertenece una nueva observación, basada en un conjunto de datos de entrenamiento con categorías conocidas.
- **Aplicaciones Comunes:**
 - Diagnóstico médico (clasificación de enfermedades)
 - Reconocimiento de imágenes (clasificación de objetos)
 - Filtrado de correos electrónicos (spam vs no spam)

Técnicas Comunes de Clasificación

- **Regresión Logística:**

- Método estadístico para modelar la probabilidad de una variable binaria
- Utiliza una función logística para limitar los valores predichos entre 0 y 1

- **K-Vecinos Más Cercanos (K-NN):**

- Clasifica basándose en la mayoría de los vecinos más cercanos a un punto de datos
- Sencillo pero puede ser computacionalmente costoso

- **Árboles de Decisión:**

- Modelo basado en reglas de decisión en forma de árbol
- Fácil de interpretar y visualizar


- **Máquinas de Vectores de Soporte (SVM):**

- Encuentra el hiperplano que maximiza el margen entre las diferentes clases
- Eficaz en espacios de alta dimensión

- **Redes Neuronales:**

- Modelos inspirados en el funcionamiento del cerebro humano
- Capaces de aprender representaciones complejas


Support vector machine: ejemplo



Support vector machine: ejemplo


Caso lineal

Separamos los puntos por rectas o planos.



Caso no lineal

Antes de separar por un plano, aplicamos una transformación de los datos.



Regresión Logística en 1 minutos



¿Cómo podemos predecir una variable binaria (0/1)?

Ajustar una función lineal $y = \beta_0 + \beta_1 x$ no va a ser apropiado

Queremos una función que para valores grandes positivos de x la función se acerque a 1 y para valores grandes negativos la función se acerque a 0.


Le aplicamos una transformación a la función lineal. Tomamos

$$y = \frac{1}{1 + e^{\beta_0 + \beta_1 x}}$$



Regresión Logística en 1 minuto

Podemos usar la curva para clasificar.



Regresión Logística en 1 minuto

- **Definición:**

- Técnica de aprendizaje supervisado utilizada para predecir la probabilidad de una variable binaria (0 o 1).

- **Aplicaciones:**

- Diagnóstico médico (ej. presencia o ausencia de enfermedad)
- Marketing (ej. probabilidad de compra de un producto)
- Finanzas (ej. riesgo de crédito)

- **Función Logística:**

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Regresión Logística en 1 minuto

- **Definición:**

- Técnica de aprendizaje supervisado utilizada para predecir la probabilidad de una variable binaria (0 o 1).

- **Aplicaciones:**

- Diagnóstico médico (ej. presencia o ausencia de enfermedad)
- Marketing (ej. probabilidad de compra de un producto)
- Finanzas (ej. riesgo de crédito)

- **Función Logística:**

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

¿Qué es el Algoritmo K-Vecinos Más Cercanos (K-NN)?

- **Definición:**

- K-NN es un algoritmo de aprendizaje supervisado utilizado para clasificación y regresión.
- Se basa en la idea de que objetos similares están cerca unos de otros.

- **Funcionamiento:**

- Para clasificar un nuevo punto, el algoritmo busca los K puntos más cercanos en el conjunto de entrenamiento.
- La categoría más común entre estos K vecinos se asigna al nuevo punto.

Características y Aplicaciones del Algoritmo K-NN

- **Ventajas:**

- Fácil de entender e implementar.
- No requiere un modelo paramétrico, lo que lo hace flexible.

- **Desventajas:**

- Computacionalmente costoso para grandes conjuntos de datos debido a la necesidad de calcular distancias.
- El rendimiento puede verse afectado por la elección del valor de K y la escala de las características.