

Laboratorio de Datos

Clustering: k -medias

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Covarianza entre dos variables

- Supongamos que tenemos dos variables X y Y con las siguientes observaciones:

$$X = [x_1, x_2, \dots, x_n], \quad Y = [y_1, y_2, \dots, y_n]$$

- La covarianza entre X y Y se calcula como:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

donde $\bar{x}$ y $\bar{y}$ son las medias de X y Y .

Matriz de Covarianza

- La matriz de covarianza mide la relación lineal entre dos o más variables.
- Dada una matriz de datos X de n observaciones y p variables, la matriz de covarianza Σ se define como:

$$\Sigma = \frac{1}{n-1} X^T X$$

- Cada elemento σ_{ij} en la matriz de covarianza representa la covarianza entre las variables X_i y X_j .

Análisis de Componentes Principales (PCA)

- PCA es una técnica para reducir la dimensionalidad de un conjunto de datos.
- Identifica las direcciones (componentes principales) que explican la mayor parte de la variabilidad en los datos.
- Los componentes principales son combinaciones lineales de las variables originales.

Cálculo de PCA

- 1 Estandarizar los datos.
- 2 Calcular la matriz de covarianza.
- 3 Obtener los eigenvalores y eigenvectores de la matriz de covarianza.
- 4 Ordenar los eigenvectores según los eigenvalores decrecientes.
- 5 Proyectar los datos originales sobre los eigenvectores seleccionados.

Relación entre Eigenvectores y Componentes Principales

- Los eigenvectores de la matriz de covarianza definen las direcciones de los componentes principales.
- Los eigenvalores indican la cantidad de varianza explicada por cada componente principal.
- Los componentes principales se obtienen proyectando los datos sobre estos eigenvectores.

$$\mathbf{Z} = \mathbf{XV}$$

donde $\mathbf{Z}$ son los componentes principales, $\mathbf{X}$ es la matriz de datos y $\mathbf{V}$ es la matriz de eigenvectores.

Ventajas de PCA

- Reducción de dimensionalidad: Permite trabajar con menos variables sin perder mucha información.
- Eliminación de redundancia: Los componentes principales son ortogonales entre sí, eliminando la multicolinealidad.
- Mejora del rendimiento de los algoritmos: Menos variables pueden resultar en tiempos de computación más rápidos.

Ejemplo Práctico

- Consideremos un conjunto de datos de flores con cuatro variables: longitud del sépalo, ancho del sépalo, longitud del pétalo, ancho del pétalo.
- Usamos PCA para reducir estas cuatro variables a dos componentes principales.
- Los dos primeros componentes principales pueden capturar la mayor parte de la variabilidad en los datos.

Conclusión

- La matriz de covarianza es esencial para entender las relaciones entre variables.
- PCA es una herramienta poderosa para simplificar datos complejos.
- La relación entre los eigenvectores de la matriz de covarianza y los componentes principales es clave para la transformación de los datos.