

Laboratorio de Datos


Clustering: k -medias

Primer Cuatrimestre 2024
Turnos tarde y noche

Facultad de Ciencias Exactas y Naturales, UBA

Análisis de Componentes Principales (PCA)

- PCA es una técnica para reducir la dimensionalidad de un conjunto de datos.
- Identifica las direcciones (componentes principales) que explican la mayor parte de la variabilidad en los datos.
- Los componentes principales son combinaciones lineales de las variables originales.



Componentes Principales - Ejemplo

- Si tenemos un conjunto de datos con 3 variables pero hay dependencia lineal entre las variables (es decir, $ax_1 + bx_2 + cx_3 \approx 0$), al representar a los puntos en el espacio, todos los puntos quedaran ubicados cerca de un plano (el plano $ax_1 + bx_2 + cx_3 = 0$)
- Si proyectamos los puntos sobre ese plano, y consideramos nuevas variables definidas por las coordenadas de las proyecciones en ese plano, estaremos representando las 3 variables originales utilizando solo 2 variables, sin perder mucha información.

Primero: varianza y covarianza

Varianza. Ya vimos la fórmula de varianza para una variable

$x = (x_1, x_2, \dots, x_n)$:

$$\text{var}(x) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n},$$

donde $\bar{x} = \sum_{i=1}^n x_i$ es el promedio o la media de los valores de x .

Covarianza. Definimos ahora la covarianza entre dos variables

$x = (x_1, x_2, \dots, x_n)$ e $y = (y_1, y_2, \dots, y_n)$ que mide la relación entre ellas:

$$\text{cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$

Interpretación: si $(y_i - \bar{y})$ es siempre positivo cuando $(x_i - \bar{x})$ es positivo, la covarianza será grande. Si uno es siempre positivo cuando el otro es negativo, la covarianza será grande negativa.

Correlación

Correlación. Dividiendo la fórmula de covarianza por los desvíos de cada variable obtenemos la fórmula de correlación:

$$\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}} = \frac{\text{cov}(x, y)}{\sigma(x)\sigma(y)}$$

Podemos reescribir esta fórmula:


$$\text{corr}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\|x\| \|y\|} = \frac{\langle (x_1 - \bar{x}, \dots, x_n - \bar{x}), (y_1 - \bar{y}, \dots, y_n - \bar{y}) \rangle}{\|x\| \|y\|},$$

donde $\langle x, y \rangle$ es el producto interno entre vectores.

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$



La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre x e y .

- Si la correlación es 1, el ángulo es 0° .
- Si la correlación es -1, el ángulo es 180° .
- Si la correlación es 0, el ángulo es 90° .

Primero: varianza y covarianza

- Supongamos que tenemos dos variables X y Y con las siguientes observaciones:

$$X = [x_1, x_2, \dots, x_n], \quad Y = [y_1, y_2, \dots, y_n]$$

- La covarianza entre X y Y se calcula como:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

donde $\bar{x}$ y $\bar{y}$ son las medias de X y Y .

Matriz de Covarianza

- La matriz de covarianza mide la relación lineal entre dos o más variables.
- Dada una matriz de datos X de n observaciones y p variables, la matriz de covarianza Σ se define como:

$$A = \frac{(X - \bar{X})^T (X - \bar{X})}{n}$$

- Si llamamos X^* a la matriz con datos normalizados $X^* = X - \bar{X}$,
 $A = \frac{(X^*)^T X^*}{n}$.
- Cada elemento A_{ij} en la matriz de covarianza representa la covarianza entre las variables x_i y x_j .

Cálculo de PCA

A partir de la matriz de covarianza, podemos calcular las componentes principales de la siguiente forma.

- 1 Calcular la matriz $X^* = X - \bar{X}$ de datos normalizados.
- 2 Calcular la matriz de covarianza $A = \frac{(X^*)^T X^*}{n}$.
- 3 Hallar matrices U ortogonal y D diagonal (con los autovalores ordenados de mayor a menor) tales que $A = UDU^T$.
- 4 Definir el nuevo conjunto de datos $Z = X^*U$ y las nuevas variables $z_1, \dots, z_p$ (las columnas de Z), con $z_i = X^*u_i$.

Relación entre Eigenvectores y Componentes Principales

- Los eigenvectores de la matriz de covarianza definen las direcciones de los componentes principales.
- Los eigenvalores indican la cantidad de varianza explicada por cada componente principal.
- Los componentes principales se obtienen proyectando los datos sobre estos eigenvectores.

$$\mathbf{Z} = \mathbf{XV}$$

donde $\mathbf{Z}$ son los componentes principales, $\mathbf{X}$ es la matriz de datos y $\mathbf{V}$ es la matriz de eigenvectores.

Ventajas de PCA

- Reducción de dimensionalidad: Permite trabajar con menos variables sin perder mucha información.
- Eliminación de redundancia: Los componentes principales son ortogonales entre sí, eliminando la multicolinealidad.
- Mejora del rendimiento de los algoritmos: Menos variables pueden resultar en tiempos de computación más rápidos.

Ejemplo Práctico

- Consideremos un conjunto de datos de flores con cuatro variables: longitud del sépalo, ancho del sépalo, longitud del pétalo, ancho del pétalo.
- Usamos PCA para reducir estas cuatro variables a dos componentes principales.
- Los dos primeros componentes principales pueden capturar la mayor parte de la variabilidad en los datos.

Conclusión

- La matriz de covarianza es esencial para entender las relaciones entre variables.
- PCA es una herramienta poderosa para simplificar datos complejos.
- La relación entre los eigenvectores de la matriz de covarianza y los componentes principales es clave para la transformación de los datos.