

LABORATORIO DE DATOS

Primer Cuatrimestre 2024

Trabajo Práctico N° 1

El Trabajo Práctico deberá ser resuelto en grupos de tres personas. La entrega se realizará a través de un *pull request* al [repositorio](#) del Trabajo Práctico, con la misma modalidad que TP-cit0. La fecha límite es el 28/05 a las 00:00. Deben entregar:

- un Notebook con la resolución de la Consigna 1 y un informe correspondiente a la Consigna 2.
- un archivo de Python con el modelo propuesto para la Consigna 2 siguiendo la estructura del archivo `plantilla.py`
- un archivo `integrantes.txt` con los nombres de quienes conforman el grupo

Se valorará que el Notebook y el código tengan un formato prolijo: ejercicios separados por títulos (Ejercicio 1, Ejercicio 2, etc.), nombres descriptivos para las variables, comentarios, etc.

Consigna 1. Trabajaremos con el dataset `sube-2023.csv`¹ que contiene datos sobre la utilización de la SUBE durante el año 2023 a nivel nacional. En este [link](#) pueden consultar el tipo y la descripción de cada variable.

- (a) Visualizar el tipo de datos de cada columna. Transformar la columna `DIA_TRANSPORTE` para que sea reconocida como una fecha.
Sugerencia: investigar la función `to_datetime` de `pandas`. Para completar el argumento `format`, revisar la [documentación](#) de `datetime`
- (b) Agregar tres columnas al DataFrame:
 - `FECHA_DIA` : debe indicar el nombre del día de la semana correspondiente a `DIA_TRANSPORTE`
 - `FECHA_ORDINAL` : debe indicar el ordinal correspondiente a `DIA_TRANSPORTE` (por ejemplo, a 2023-01-01 le corresponde 1, a 2023-01-02 le corresponde 2 y así sucesivamente). Debe ser un entero (`int`).
 - `FECHA_MES` : debe indicar el mes correspondiente a `DIA_TRANSPORTE`
2. Crear el DataFrame `datos_amba`, el cual sólo debe tener datos de AMBA y debe excluir datos preliminares. Además, al ejecutar `datos_amba.head()` debe observarse el siguiente formato:

	fecha	fecha_dia	fecha_mes	fecha_ordinal	jurisdiccion	linea	pasajeros	tipo_transporte
0	2023-01-01	Sun	01	1	MUNICIPAL	1	61	COLECTIVO
1	2023-01-01	Sun	01	1	MUNICIPAL	2B	11	COLECTIVO
3	2023-01-01	Sun	01	1	PROVINCIAL	BS_AS_LINEA_326	438	COLECTIVO
5	2023-01-01	Sun	01	1	MUNICIPAL	BS_AS_LINEA_514	3067	COLECTIVO
6	2023-01-01	Sun	01	1	MUNICIPAL	BS_AS_LINEA_522	332	COLECTIVO

¹Fuente: <https://datos.transporte.gob.ar/dataset/sube-cantidad-de-transacciones-usos-por-fecha>

3. Utilizando `datos_amba`, identificar:

- (a) la proporción de la cantidad total anual de pasajeros que le corresponde a cada medio de transporte
- (b) la tupla (mes, línea de subte) donde viajó la mayor cantidad de pasajeros
- (c) la fecha del día hábil² de menor cantidad de pasajeros promedio entre los colectivos de jurisdicción municipal.
- (d) el día hábil con menor variabilidad en cantidad de pasajeros

4. Elaborar un gráfico que permita comparar la media y los cuartiles de la cantidad anual de pasajeros en los días hábiles para cada una de las nueve líneas de colectivo que llegan a Ciudad Universitaria.

5. *Análisis exploratorio*. La idea de este ítem es que realicen un análisis exploratorio de los datos, aplicando las herramientas de visualización (`seaborn.objects`, `seaborn` y/o `matplotlib`) y de resumen de datos (media, mediana, desvío estándar, operaciones sobre el `DataFrame`, etc.).

El objetivo es entender, comparar y/o estudiar aspectos o patrones en la cantidad de pasajeros del transporte público. Algunas preguntas disparadoras pueden ser:

- ¿Cómo varía el uso del transporte público a lo largo del año? ¿Se observa el mismo efecto en AMBA y en el interior del país? ¿Y en todos los medios de transporte por igual?
- ¿Cómo difiere el uso del transporte público durante los días hábiles en comparación a los fines de semana?
- ¿Hay algún día hábil que resulte un outlier? ¿Pueden explicarlo?

No es necesario que respondan a cada una de esas preguntas, pueden explorar por donde se les ocurra. Tampoco están limitados a usar sólo el dataset de 2023 (en el link hay datasets desde 2020 a 2024). Pueden hacer comparaciones interanuales, enfocarse en un solo tipo de transporte, etc.

En el Notebook, las visualizaciones y resúmenes de datos que realicen deben estar acompañados por las conclusiones que obtengan a partir de ellos.

6. *Modelo de regresión*. En este ítem, intentaremos ajustar la cantidad de pasajeros que viajan por día en una línea de colectivos utilizando la información de pasajeros por día de otras líneas.

- (a) Generar un `DataFrame` en el que las columnas sean las líneas de colectivo (`TIPO_TRANSPORTE == "COLECTIVO"`) de AMBA de jurisdicción nacional (`PROVINCIA == "JN"`) y las observaciones sean los días del año. Es decir, cada fila del `DataFrame` corresponde a un día del año, y en esa fila deben figurar la cantidad de pasajeros que viajaron en cada línea de colectivo en el día correspondiente.

Para generar el `DataFrame` pueden completar el siguiente código.

```
datos_ColectivoJN = datos_AMBA[???]
cols = datos_ColectivoJN.LINEA.unique() # Los nombres de
    las líneas de colectivo

pasajeros_por_linea = pd.DataFrame()
for col in cols:
```

²Consideramos como día hábil a cualquier día, salvo Sábado y Domingo, sin importar si es feriado.

```

datos_linea = datos_ColectivoJN[datos_ColectivoJN.LINEA
== col][["DIA_TRANSPORTE", "CANTIDAD"]]
datos_linea =
datos_linea.set_index("DIA_TRANSPORTE").rename(columns =
{"CANTIDAD" : col})
pasajeros_por_linea = pd.concat([pasajeros_por_linea,
datos_linea], axis = 1)

```

- (b) Eliminar las columnas correspondientes a líneas de colectivo que tengan datos faltantes.
- (c) Se quiere ajustar la cantidad de pasajeros en la línea BSAS_LINEA_009 en función de los pasajeros en otras líneas. Proponer tres modelos de regresión distintos. En cada modelo, pueden utilizarse la información solo de otras 5 líneas de colectivos (pueden ser distintas líneas de colectivo en los distintos modelos). Los criterios de selección de esas 5 columnas los determinan ustedes, y deben estar explicitados en el informe.
- (d) Si alguno de los modelos es Regresión Ridge, determinar mediante un esquema de validación el hiperparámetro α .
- (e) Proponer un esquema de validación de los modelos y utilizarlo para seleccionar el mejor de los tres modelos propuestos.
- (f) Para el modelo elegido, indicar la fórmula final de modelo.
- (g) Los modelos propuestos por los distintos grupos serán testeados en un conjunto de testeo conteniendo días distintos a los utilizados para la construcción del modelo. Los equipos que tengan los mejores desempeños obtendrán un punto bonus en la nota del TP.