

LABORATORIO DE DATOS

Primer Cuatrimestre 2024

Trabajo Práctico N° 2

El Trabajo Práctico deberá ser resuelto en grupos de dos o tres personas. No se aceptarán entregas individuales. La entrega se realizará a través del campus (pestaña Trabajos Prácticos). La fecha límite es el 28/05 a las 23:59. Deben entregar un Notebook con los nombres de los integrantes del equipo, la resolución de los ejercicios y los informes pertinentes.

Se valorará que el Notebook y el código tengan un formato prolijo: ejercicios separados por títulos (Ejercicio 1, Ejercicio 2, etc.), nombres descriptivos para las variables, comentarios, etc.

En este trabajo práctico nos sumamos a la moda de utilizar análisis de datos para la toma de decisiones en los deportes, y creamos nuestra propia empresa LDD Futbol Analytics.

Trabajaremos con el dataset `FBRef2020-21.csv`¹ que contiene datos sobre los principales torneos de clubes y selecciones de fútbol del mundo.

Preprocesamiento [2 pt.]

Clustering [4 pts.]

1. Nuestro primer objetivo es realizar algún agrupamiento de jugadores con características similares.
 - (a) Seleccionar dos variables cualesquiera de los datos y realizar un gráfico de dispersión de una variable en función de la otra para el total de las observaciones. ¿Pueden encontrar fácilmente grupos distintos?
 - (b) Escalar los datos y realizar un análisis de componentes principales, quedándose solo con las dos primeras componentes. Realizar un gráfico como el del punto anterior. ¿Cuántos clusters puede distinguir en el gráfico? ¿A qué características de los jugadores pueden corresponder los clusters? ¿Cómo pueden verificar su conjetura? (realizar una visualización o algún cálculo)
 - (c) Para la cantidad de clusters observados en el ítem anterior, realizar un agrupamiento por k -medias, y colorear los puntos según las etiquetas obtenidas. Coinciden las etiquetas con lo esperado?
 - (d) Repetir el agrupamiento utilizando DBSCAN. ¿Cómo elegirían en este caso un valor de ε apropiado? Sugerencia: consultar la sección "Selección del hiperparámetro eps" del Notebook de la clase de DBSCAN (o utilizar cualquier otra técnica que consideren apropiada)
 - (e) Para realizar el clustering pueden utilizar como datos todas las variables originales o solo las dos componentes principales. Si en el ítem anterior utilizaron una de estas alternativas, repitan el experimento utilizando la otra alternativa (modificando los valores de epsilon y minPts convenientemente). ¿Con cuál de las dos opciones obtienen mejores resultados?

¹Fuente: <https://fbref.com/en/>

Clasificación [3 pts.]

2. Ahora queremos poder predecir la posición en la que juega cada jugador según sus datos estadísticos utilizando *KNN*. En la columna Pos encontramos la posición de los jugadores. Para la mayoría de los jugadores se indica una única posición pero algunos jugadores tienen dos posiciones. Para simplificar el análisis vamos a considerar una única posición por jugador.
- (a) Elegir alguna opción para quedarse con una única posición por jugador (pueden quedarse solo con la primera o eliminar a los jugadores con dos posiciones o alguna otra estrategia que se les ocurra).
 - (b) Construir una base de datos X con las variables explicativas e y con las variable de posición.
 - (c) Dividir ambos conjunto de datos en un 80% para entrenamiento y un 20% para testeo.
 - (d) Aplicar un esquema de validación en el conjunto de entrenamiento para seleccionar el valor óptimo de K . (Esto puede demorar mucho si prueban mucho, hacerlo hasta un valor máximo de $K = 20$.)
 - (e) Para el valor de K obtenido, ¿cuál es el porcentaje de aciertos en el conjunto de testeo?
 - (f) Al igual que en el caso de clustering, pueden realizar la clasificación utilizando todas las variables o solo las primeras componentes principales. Utilizar ambos métodos e indicar con cuál método obtienen mejores resultados.

Redes neuronales [1 pts.]

3. Trabajamos ahora con el dataset de jugadoras de la 2023-2024 Women's Super League de Inglaterra. ¿Cómo podemos predecir la posición en qué juega cada jugadora utilizando redes neuronales? ¿Qué porcentaje de aciertos obtienen?